Justus-Liebig-Universität Gießen

Masterstudiengang Data Science

Advanced Data Analytics

E-Portfolio

Porto Seguro Safe Driver Prediction

Machine-Learning-gestützte Vorhersage
von Versicherungsschäden

Verfasst von	Gilles Armel Takoufouet Koudjou
Matrikelnummer	8216595
Studiengang	M.Sc. Data Science
Gruppennummer	108
Gruppenmitglieder	Leyla Louache, Alawil Mariam, Melchi Dangui
Sprecherin	Leyla Louache

Sommersemester 2026

Inhaltsverzeichnis

1 Zusammenfassung des Logbuchs **1**

1.1 Fragestellung und Zielsetzung . . . 1
1.2 Explorative Datenanalyse . . . 1
1.3 Datenaufbereitung . . . 2
1.4 Modellierung und experimentelles Vorgehen . . . 2
1.5 Ensemble-Modelle . . . 3
1.6 Finale Evaluation und Ergebnisse . . . 4
1.7 Schwierigkeiten und Limitationen . . . 4
1.8 Fazit und Ausblick . . . 4

2 Einschätzung der Gruppenmitglieder **5**

3 Individuelles Logbuch **6**

30.07.2026 – Projektstart und gemeinsame Arbeitsplanung . . . 6
02.08.2026 – Explorative Datenanalyse . . . 6
09.08.2026 – Datenaufbereitung und Logistic-Regression-Baseline . . . 10
09.08.2026 – XGBoost-Basismodell . . . 12
12.08.2026 – XGBoost-Hyperparameteroptimierung . . . 12
12.08.2026 – AP- vs. ROC-AUC/Gini-Ranking . . . 13
12.08.2026 – Gewichtetes vs. nicht gewichtetes XGBoost . . . 14
17.08.2026 – Lineare SVM: Baseline und Tuning . . . 15
17.08.2026 – Ensemble-Ansätze aus XGBoost und SVM . . . 17
19.08.2026 – Finale Testevaluation der eigenen Modelle . . . 18
21.08.2026 – Einfluss der ps_calc-Merkmale . . . 19
28.08.2026 – Abschluss und Einordnung der Ergebnisse . . . 20

4 Quellen und Hilfsmittel **20**

1 Zusammenfassung des Logbuchs

1.1 Fragestellung und Zielsetzung

Im Projekt wird der Datensatz *Porto Seguro Safe Driver Prediction* untersucht. Ziel ist die Vorhersage, ob eine versicherte Person einen Schadenfall verursacht bzw. einen Versicherungsanspruch stellt. Damit liegt eine binäre Klassifikationsaufgabe vor.

Im Mittelpunkt meiner Arbeit stand die Frage, wie gut unterschiedliche Machine-Learning-Verfahren diese Zielvariable vorhersagen und ob die Kombination verschiedener Modellansätze die Leistung gegenüber Einzelmodellen verbessern kann. Als Baseline wurde eine logistische Regression verwendet; der Schwerpunkt lag anschließend auf XGBoost, einer linearen SVM sowie Ensembles aus beiden Modellen.

1.2 Explorative Datenanalyse

Der untersuchte Datensatz umfasst insgesamt 589 889 Beobachtungen und 57 Eingangsmerkmale. Die explorative Analyse zeigte zunächst eine stark unausgeglichene Zielvariable: 569 878 Beobachtungen (96,61 %) gehören zur Klasse `target = 0`, während lediglich 20 011 Beobachtungen (3,39 %) der positiven Klasse `target = 1` zugeordnet sind (Abb. 1).

Damit wäre Accuracy allein für die Modellbewertung wenig aussagekräftig. Diese Beobachtung war ein wesentlicher Grund dafür, ROC-AUC bzw. den daraus abgeleiteten Gini-Koeffizienten als primäre Evaluationsmetriken und Average Precision ergänzend für die seltene positive Klasse zu verwenden.

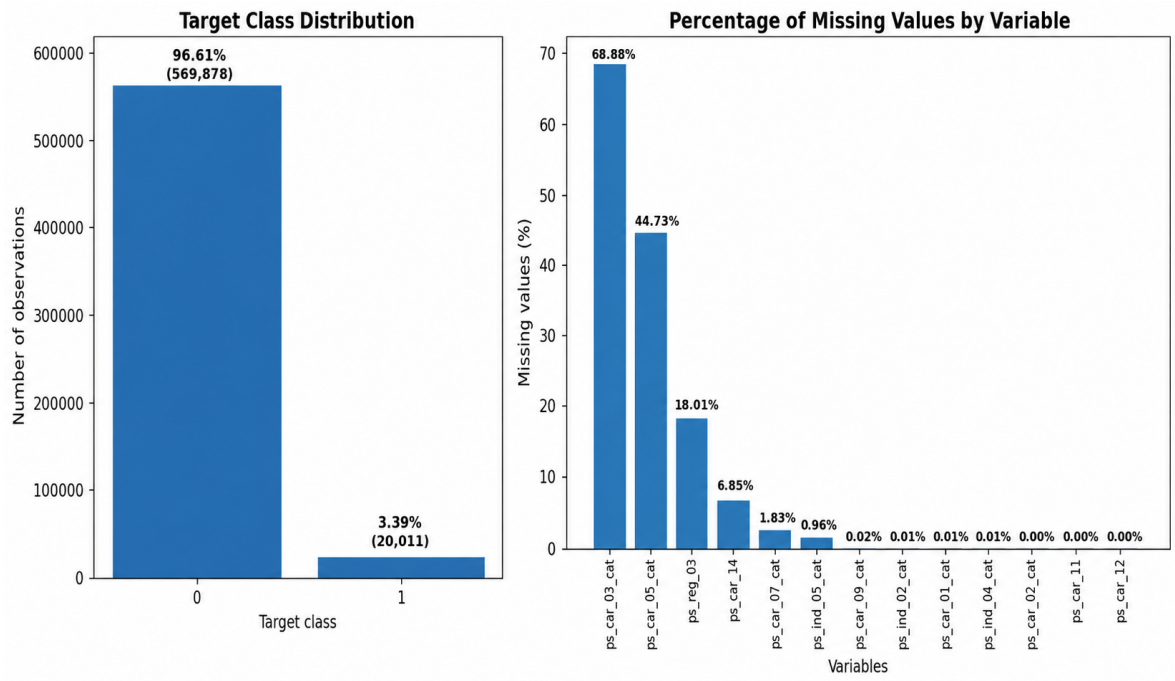


Abbildung 1: Verteilung der Zielvariable und Anteil fehlender Werte.

Auch die fehlenden Werte sind sehr ungleich über die Merkmale verteilt. Besonders betroffen sind `ps_car_03_cat` mit 68,88 %, `ps_car_05_cat` mit 44,73 % und `ps_reg_03` mit 18,01 % fehlenden Beobachtungen. Damit stellte der Umgang mit Missing Values einen relevanten Teil der späteren Datenaufbereitung dar.

Darüber hinaus wurden die Verteilungen numerischer, binärer und kategorialer Merkmale sowie mögliche Unterschiede zwischen den beiden Zielklassen untersucht. Die Korrelationsanalyse zeigte überwiegend schwache lineare Zusammenhänge einzelner Merkmale mit der Zielvariable, während

zwischen einigen erklärenden Variablen deutlich stärkere Beziehungen bestanden (Abb. 2).

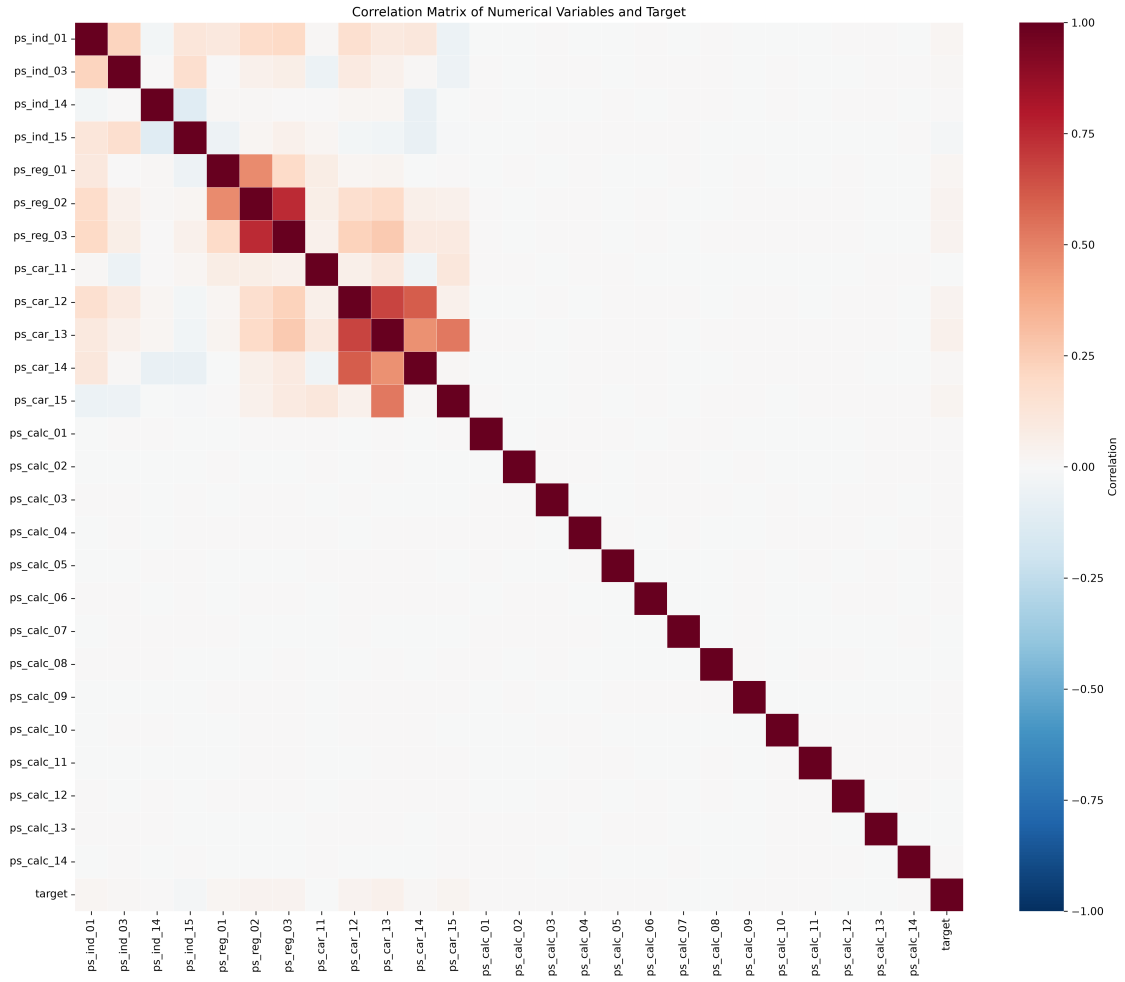


Abbildung 2: Korrelationsstruktur der numerischen Merkmale und der Zielvariable.

Weitere Merkmalsverteilungen, Boxplots, Ausreißer und Vergleiche zwischen den Zielklassen sind im EDA-Teil des Logbuchs dokumentiert.

1.3 Datenaufbereitung

Der Datensatz wurde stratifiziert im Verhältnis 80:20 in Trainings- und Testdaten aufgeteilt. Der Testdatensatz blieb während der gesamten Modellentwicklung unberührt und wurde erst für die finale Evaluation verwendet.

Numerische und kategoriale Merkmale wurden getrennt verarbeitet. Fehlende numerische Werte wurden durch den Median ersetzt; für kategoriale Merkmale wurden die häufigste Kategorie und anschließend One-Hot-Encoding verwendet. Sämtliche Transformationen wurden ausschließlich auf den Trainingsdaten angepasst, um Data Leakage zu vermeiden.

1.4 Modellierung und experimentelles Vorgehen

Als Referenz wurde zunächst eine logistische Regression trainiert, um die Leistung der späteren komplexeren Modelle einordnen zu können. Anschließend wurden XGBoost und eine lineare SVM untersucht. Für vergleichbare Experimente wurden dieselben drei gespeicherten Cross-Validation-Folds verwendet, während der Testdatensatz vollständig von der Modellauswahl getrennt blieb.

Für XGBoost erfolgte nach einem Basismodell eine Hyperparameteroptimierung mittels Randomized Search. Dabei zeigte sich, dass die Rangfolge der Konfigurationen nach Average Precision nicht

vollständig mit der Rangfolge nach ROC-AUC/Gini übereinstimmte.

Bei der linearen SVM wurden insbesondere der Regularisierungsparameter C und verschiedene Einstellungen von `class_weight` systematisch untersucht.

Tabelle 1 fasst zur kompakten Einordnung die später auf dem zurückgehaltenen Testdatensatz erzielten Ergebnisse der drei Einzelmodell-Ansätze zusammen. Die eigentliche Modellauswahl und Hyperparameteroptimierung erfolgte jedoch ausschließlich anhand der Cross-Validation auf den Trainingsdaten.

Modell	ROC-AUC	Gini	AP
Logistische Regression	0,6276	0,2553	0,0605
Lineare SVM	0,6277	0,2554	0,0599
XGBoost	**0,6398**	**0,2795**	**0,0667**

Tabelle 1: Finale Testleistung der untersuchten Einzelmodelle.

Aufgrund der starken Klassenungleichverteilung wurde zusätzlich in einem kontrollierten Experiment untersucht, ob eine höhere Gewichtung der positiven Klasse die XGBoost-Leistung verbessert. Gewichtete und nicht gewichtete Varianten wurden hierfür unter identischen Cross-Validation-Folds verglichen.

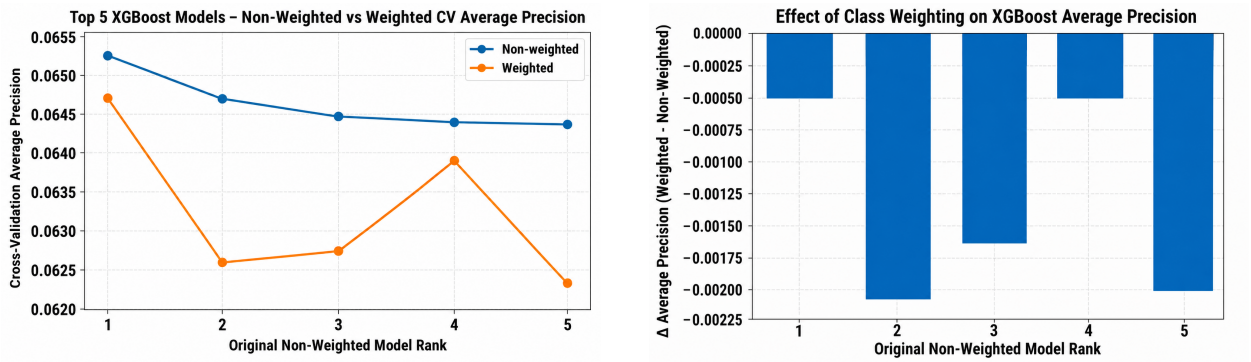


Abbildung 3: Vergleich gewichteter und nicht gewichteter XGBoost-Varianten sowie Einfluss der Klassengewichtung auf die Modellleistung.

Die Gewichtung führte nicht zu einer Verbesserung der für die Modellauswahl primären ROC-AUC/Gini-Werte. Daher wurde die nicht gewichtete XGBoost-Variante für die nachfolgenden Ensemble-Experimente verwendet.

Ein ergänzender Vergleich mit und ohne `ps_calc`-Merkmale ist im Logbuch dokumentiert.

Die vollständigen Zwischenresultate befinden sich im XGBoost-Teil und im SVM-Teil des Logbuchs.

1.5 Ensemble-Modelle

Auf Basis der optimierten XGBoost- und SVM-Modelle wurden drei Ensemble-Strategien untersucht: *Simple Average*, *Weighted Average* und *Stacking*. Ziel war zu prüfen, ob die unterschiedlichen Modellierungsansätze komplementäre Informationen liefern und dadurch gemeinsam eine höhere Vorhersageleistung erreichen können.

Der einfache 50/50-Mittelwert erzielte in der Cross-Validation einen ROC-AUC von 0,6351. Anschließend wurden unterschiedliche Gewichte für XGBoost und SVM systematisch verglichen (Abb. 20). Die optimierte Kombination erhöhte den ROC-AUC auf 0,6374 (Gini: 0,2748).

Als dritte Strategie wurde ein Stacking-Modell untersucht. Hierzu wurden Out-of-Fold-Vorhersagen

von XGBoost und SVM als Merkmale für eine logistische Regression als Meta-Learner verwendet. Das Stacking erreichte einen ROC-AUC von 0,6373.

Die Ergebnisse zeigen somit, dass die optimierte Gewichtung einen kleinen Vorteil gegenüber dem einfachen Mittel brachte, während die höhere Komplexität des Stackings keinen zusätzlichen relevanten Leistungsgewinn erzeugte. Weitere Details zur Gewichtssuche und zum Stacking sind im Ensemble-Teil des Logbuchs dokumentiert.

1.6 Finale Evaluation und Ergebnisse

Nach Abschluss der Modellauswahl wurden alle finalen Ansätze einmalig auf dem zurückgehaltenen Testdatensatz evaluiert. Abbildung 4 zeigt ROC-AUC, Gini und AP der untersuchten Modelle.

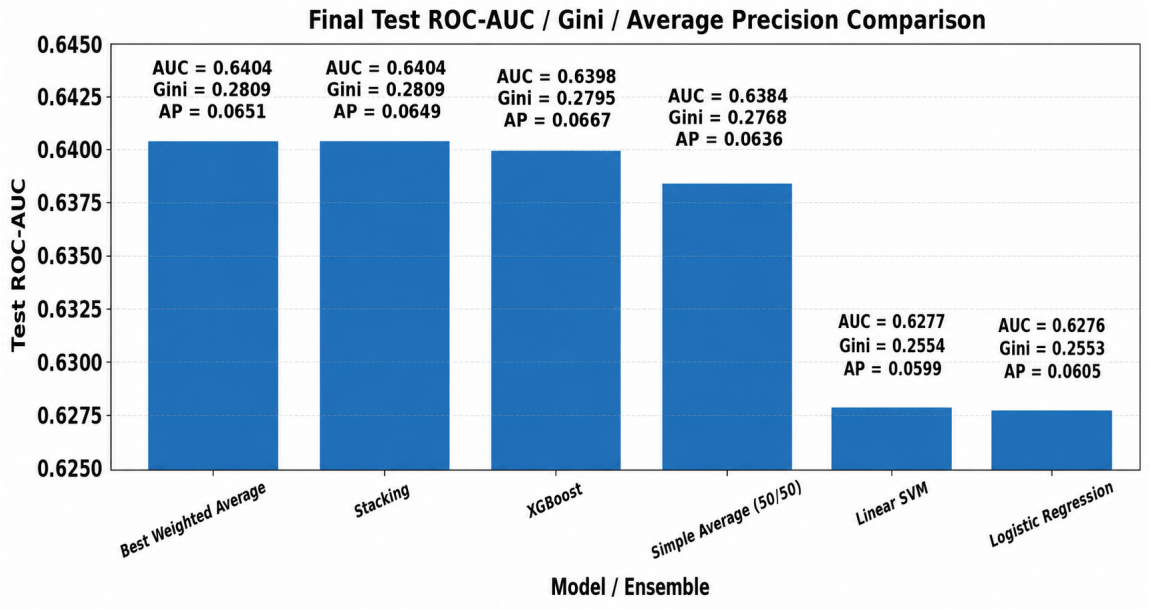


Abbildung 4: Finaler Vergleich der eigenen Modelle auf dem Testdatensatz.

Das Weighted-Average-Ensemble erzielte mit ROC-AUC 0,6404 (Gini: 0,2809) das beste Ergebnis. Das Stacking lag nahezu gleichauf. XGBoost erreichte als Einzelmodell einen Gini von 0,2795 und mit AP = 0,0667 gleichzeitig den höchsten AP-Wert.

SVM und logistische Regression lagen mit Gini-Werten von jeweils etwa 0,255 deutlich darunter.

Weitere Darstellungen befinden sich im Logbuch zur finalen Evaluation.

1.7 Schwierigkeiten und Limitationen

Die Untersuchung unterliegt mehreren Einschränkungen. Aufgrund der begrenzten Rechenkapazität konnte nur ein begrenzter Hyperparameterraum untersucht werden, sodass die gefundenen Konfigurationen nicht als globale Optima zu verstehen sind.

Zudem wurden die Modelle unterschiedlich intensiv optimiert: Während XGBoost und SVM systematisch getunt wurden, diente die logistische Regression hauptsächlich als Baseline.

Schließlich basieren die Ergebnisse auf einer festen Zufallsinitialisierung.

1.8 Fazit und Ausblick

Insgesamt erwies sich XGBoost als deutlich stärker als die untersuchten linearen Ansätze, während die Ensemble-Modelle nur einen geringen zusätzlichen Leistungsgewinn erzielten. Weiterführend sollten die Stabilität der Ergebnisse über mehrere Datenaufteilungen und Seeds sowie mögliche Verbesserungen durch Wahrscheinlichkeitskalibrierung untersucht werden.

2 Einschätzung der Gruppenmitglieder

Mariam Alawil

Stärken: Mariam zeigte sich während der Zusammenarbeit offen für Kritik und Vorschläge und setzte sich konstruktiv mit den Ideen der anderen Gruppenmitglieder auseinander. Ihre ruhige Art trug dazu bei, unterschiedliche Ansätze in den Diskussionen zu berücksichtigen.

Schwächen: Bei der Vorstellung ihrer eigenen Arbeit wirkte sie teilweise unsicher, obwohl ihre Ergebnisse eine gute Grundlage für die gemeinsame Arbeit darstellten. Eine selbstbewusstere Kommunikation ihrer Ergebnisse hätte deren Einordnung innerhalb der Gruppe erleichtert.

Leyla Louache

Stärken: Leyla brachte insbesondere zu Beginn des Projekts eigene Ideen zur Strukturierung und zum weiteren Vorgehen ein. Dabei zeigte sie ein gutes Verständnis der verwendeten methodischen Ansätze und beteiligte sich aktiv an der Entwicklung möglicher Lösungswege.

Schwächen: Bei der direkten Diskussion eigener Ergebnisse war sie teilweise eher zurückhaltend. Ein intensiverer Austausch wäre insbesondere bei ähnlichen oder sich -mit meinen- überschneidenden Experimenten hilfreich gewesen, um Ergebnisse früher miteinander zu vergleichen und Doppelarbeit zu vermeiden.

Melchi Dangui

Stärken: Melchi zeigte während der Projektarbeit großes Interesse an den methodischen Details und stellte regelmäßig Fragen, um Ergebnisse und Vorgehensweisen besser nachzuvollziehen. Dies förderte die Diskussion und führte teilweise auch zu neuen Überlegungen innerhalb der Gruppe.

Schwächen: Teilweise wollte er einzelne Arbeitsschritte sehr schnell vorantreiben, wodurch die Abstimmung innerhalb der Gruppe nicht immer vollständig gegeben war. Eine etwas stärkere Koordination vor dem Übergang zum nächsten Arbeitsschritt hätte die gemeinsame Arbeitsweise erleichtert.

3 Individuelles Logbuch

Das Logbuch dokumentiert meinen individuellen Arbeitsprozess chronologisch. Neben den durchgeführten Schritten werden insbesondere Fragestellungen, Entscheidungen, Zwischenresultate, Schwierigkeiten, verworfene Varianten und die Auswirkungen der Gruppentreffen auf meine weitere Arbeit festgehalten.

Donnerstag, 30.07.2026 – Projektstart und gemeinsame Arbeitsplanung

Ausgangssituation / Ziel:

Im ersten gemeinsamen Treffen wurden die Anforderungen des Projekts besprochen und die organisatorische Grundlage für die Zusammenarbeit festgelegt.

Gemeinsame Entscheidungen:

- Jedes Gruppenmitglied sollte zunächst eine eigene explorative Datenanalyse durchführen. Dadurch sollte jedes Mitglied ein eigenes Verständnis des Datensatzes entwickeln, anstatt sich auf die Analyse einer anderen Person zu verlassen.
- Zur gemeinsamen Organisation wurde ein GitHub-Repository vorgesehen, in dem jedes Gruppenmitglied ein eigenes Notebook bearbeitet.
- Zusätzlich war zunächst geplant, zentrale EDA-Ergebnisse und den Train-Test-Split später in einem gemeinsamen Notebook zusammenzuführen.
- Die Ergebnisse der individuellen Analysen sollten im nächsten Treffen verglichen werden, bevor die Machine-Learning-Modelle endgültig verteilt werden.

Auswirkung auf meine Arbeit:

Direkt aus dieser Entscheidung ergab sich als erster individueller Arbeitsschritt eine eigenständige EDA des Porto-Seguro-Datensatzes. Die ursprünglich geplante Zusammenführung der vier EDA-Analysen wurde später im zweiten Gruppentreffen verworfen, da dadurch viele redundante Inhalte entstanden wären.

Sonntag, 02.08.2026 – Explorative Datenanalyse

Fragestellung:

Welche Eigenschaften des Porto-Seguro-Datensatzes sind für die spätere Modellierung besonders relevant? Im Mittelpunkt standen dabei die Klassenverteilung, fehlende Werte, unterschiedliche Merkmalstypen, Korrelationen sowie mögliche Unterschiede zwischen den beiden Zielklassen.

Vorgehen:

- Untersuchung der Verteilung von `target`.
- Analyse der im Datensatz durch -1 kodierten fehlenden Werte.
- Untersuchung numerischer, binärer und kategorialer Merkmale.
- Erstellung einer Korrelationsmatrix für numerische Variablen.
- Vergleich ausgewählter Merkmale zwischen `target = 0` und `target = 1`.
- Untersuchung von Verteilungen und Ausreißern.

Ergebnisse und Interpretation:

Die Zielvariable erwies sich als stark unausgeglichen. Nur etwa 3,4 % der Beobachtungen gehören zur positiven Klasse. Damit wurde früh deutlich, dass Accuracy allein keine sinnvolle Hauptmetrik für die spätere Modellbewertung sein würde.

Zusätzlich zeigte sich, dass fehlende Werte sehr ungleich über die Variablen verteilt sind. Besonders hohe Missing-Raten traten unter anderem bei `ps_car_03_cat` und `ps_car_05_cat` auf.

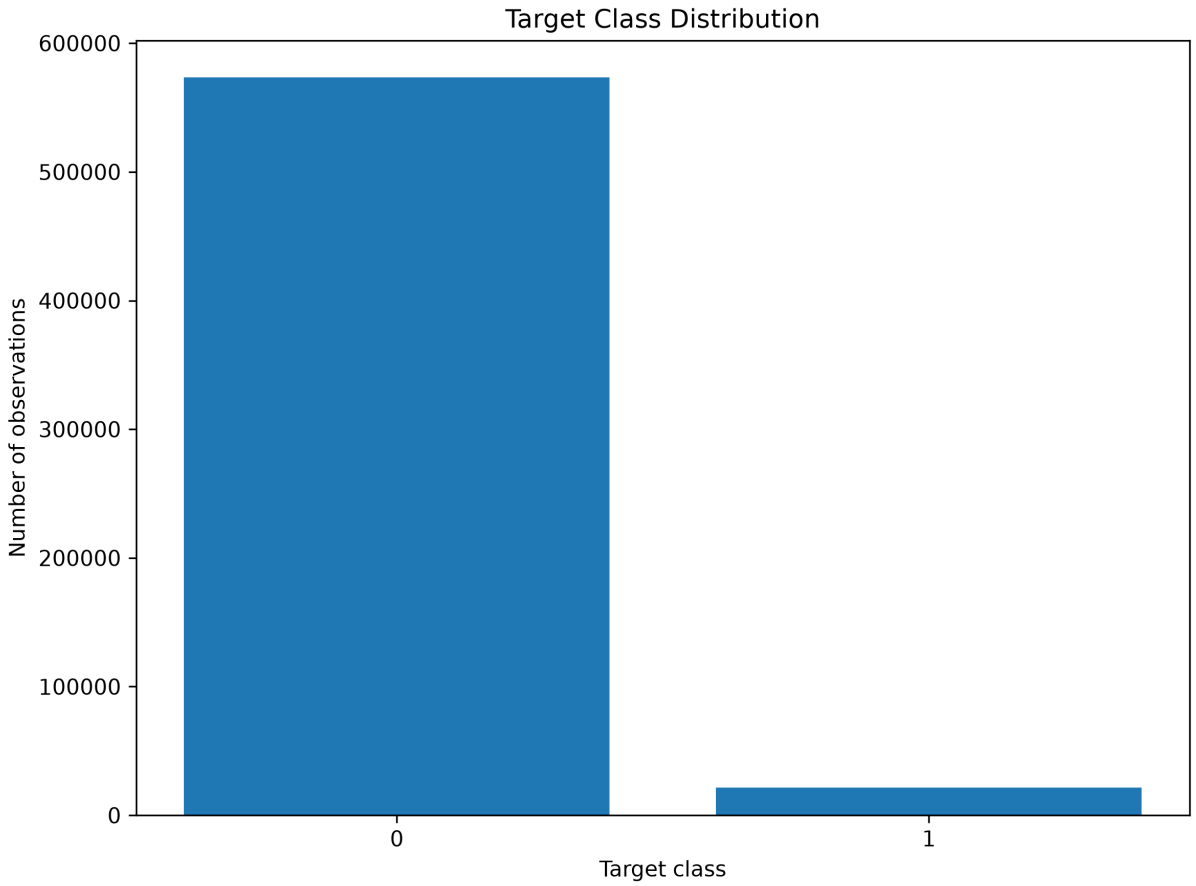


Abbildung 5: Verteilung der Zielvariable während der EDA.

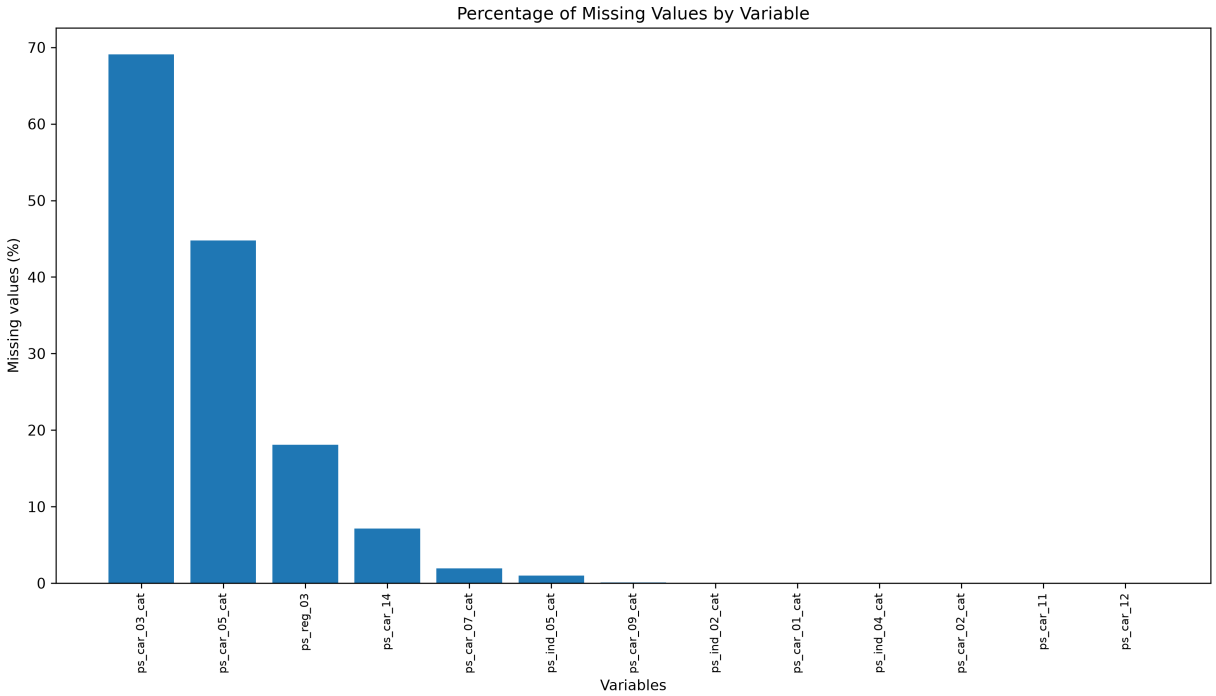


Abbildung 6: Anteil fehlender Werte in den betroffenen Variablen.

Die Korrelationsanalyse zeigte nur schwache lineare Beziehungen einzelner Merkmale zur Zielvariable, während zwischen einigen erklärenden Variablen deutlich stärkere Zusammenhänge bestanden.

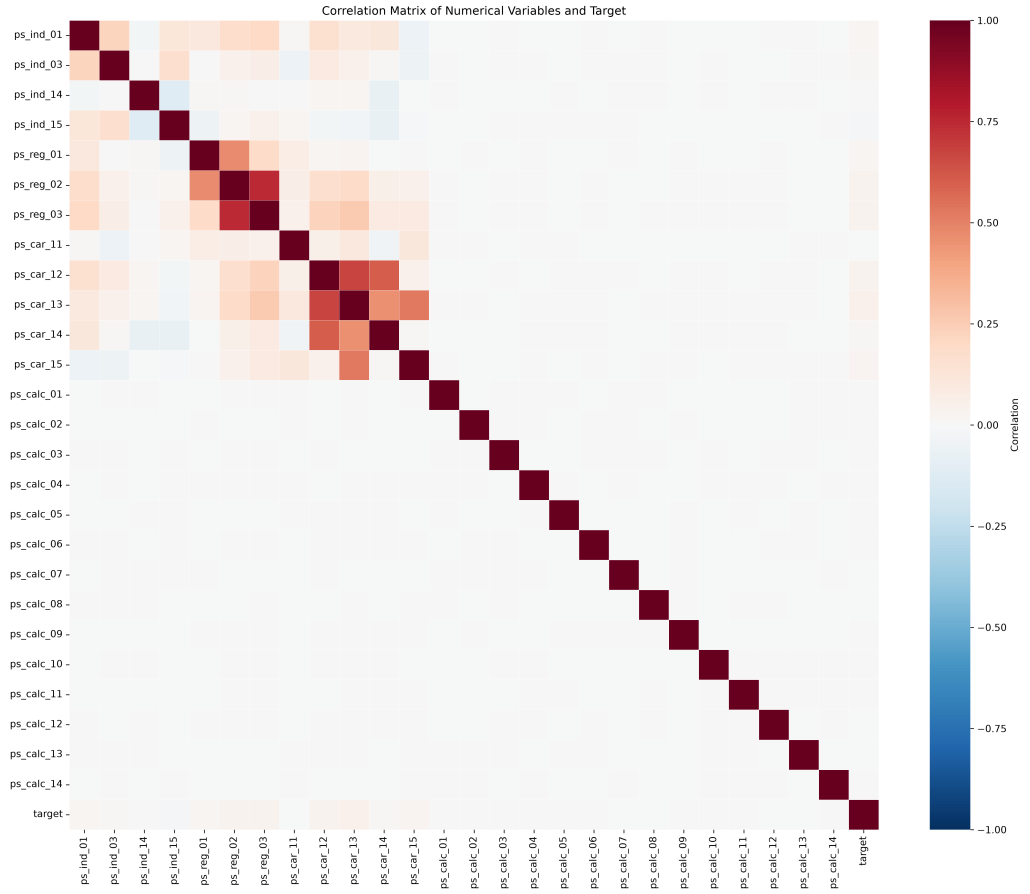


Abbildung 7: Korrelationsmatrix der numerischen Merkmale und der Zielvariable.

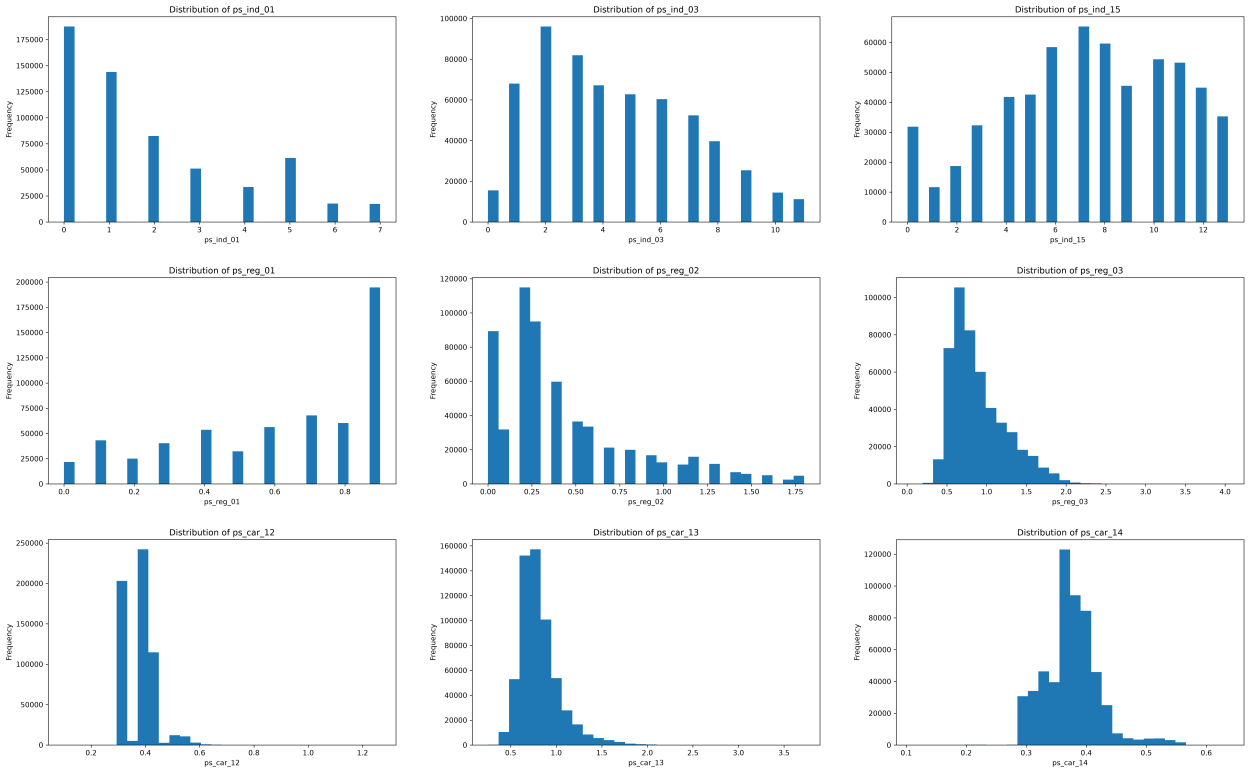


Abbildung 8: Ausgewählte Verteilungen numerischer Nicht-`ps_calc`-Merkmale.

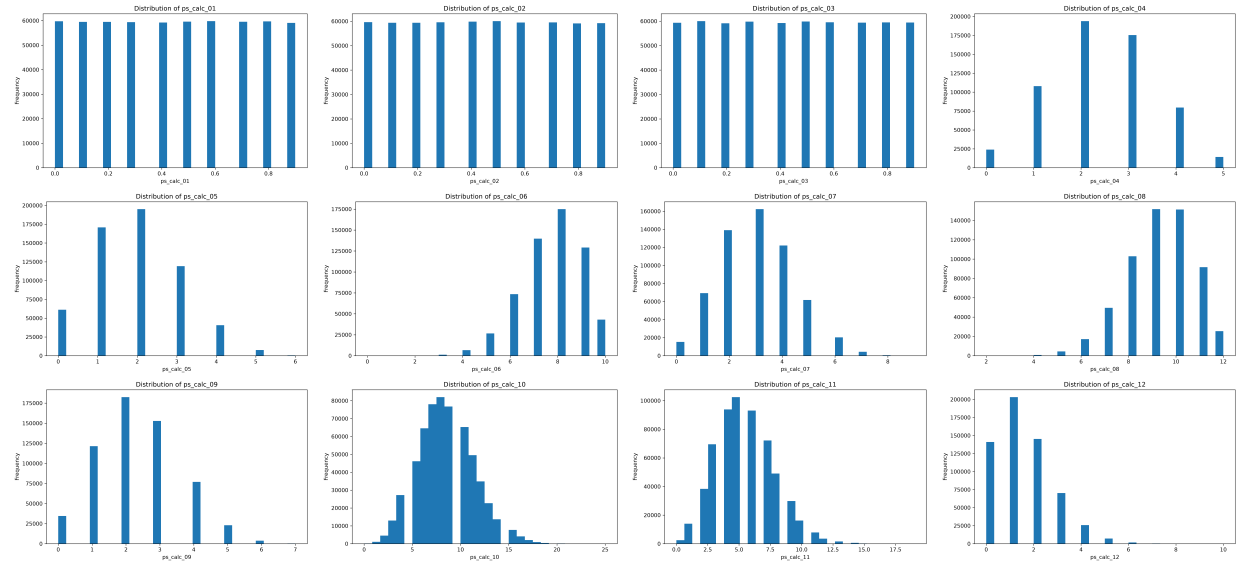


Abbildung 9: Verteilungen ausgewählter numerischer `ps_calc`-Merkmale.

Auch die Vergleiche einzelner Variablen nach Zielklasse zeigten meist eine starke Überlappung. Bei einigen Variablen waren jedoch leichte Verschiebungen erkennbar, beispielsweise bei `ps_reg_03`.

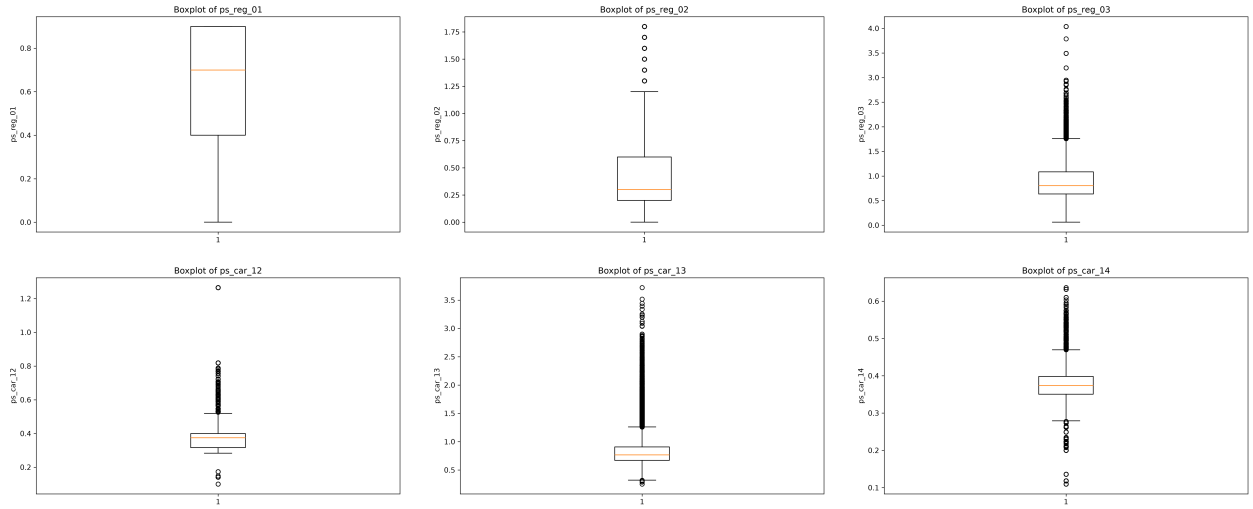


Abbildung 10: Vergleich ausgewählter numerischer Merkmale zwischen den beiden Zielklassen.

Konsequenz / offene Fragen:

Die EDA deutete darauf hin, dass die Zielklasse nicht über ein einzelnes Merkmal klar separiert werden kann. Daher erschienen Modelle sinnvoll, die mehrere Variablen gemeinsam und gegebenenfalls nichtlinear verarbeiten können. Gleichzeitig musste die Klassenungleichverteilung bei der Wahl der Evaluationsmetriken berücksichtigt werden.

Sonntag, 09.08.2026 – Datenaufbereitung und Logistic-Regression-Baseline

Bezug zum Gruppentreffen vom 08.08.2026:

Im zweiten Gruppentreffen wurden die individuellen EDA-Ergebnisse verglichen. Die Gruppe entschied, die EDA-Notebooks getrennt zu behalten und für spätere Vergleiche denselben Train-Test-Split mit `random_state=42` zu verwenden. Zusätzlich wurde der normalisierte Gini-Koeffizient als zentrale Vergleichsmetrik festgelegt. XGBoost wurde mir als primär zu untersuchendes Modell zugeteilt.

Fragestellung:

Wie müssen die Daten vorbereitet werden, damit die unterschiedlichen Modelle unter vergleichbaren Bedingungen trainiert und evaluiert werden können?

Vorgehen:

- Stratifizierter Train-Test-Split im Verhältnis 80:20.
- Trennung numerischer und kategorialer Variablen.
- Median-Imputation für numerische Merkmale.
- Imputation mit der häufigsten Kategorie für kategoriale Merkmale.
- One-Hot-Encoding der kategorialen Merkmale mit `handle_unknown=ignore"`.
- Anpassung des Preprocessings ausschließlich auf `X_train`, um Data Leakage zu vermeiden.

Erste Referenz: Logistische Regression

Vor dem komplexeren XGBoost-Modell wurde eine logistische Regression als Baseline eingesetzt. Damit sollte zunächst überprüft werden, welche Leistung ein einfaches lineares Verfahren auf denselben aufbereiteten Daten erreicht.

Die Out-of-Fold-Evaluation ergab einen ROC-AUC von 0,6234 und einen daraus abgeleiteten Gini-Koeffizienten von 0,2469. Die ROC-Kurve zeigt damit eine Vorhersageleistung oberhalb einer zufälligen Klassifikation, gleichzeitig aber noch deutliches Verbesserungspotenzial.

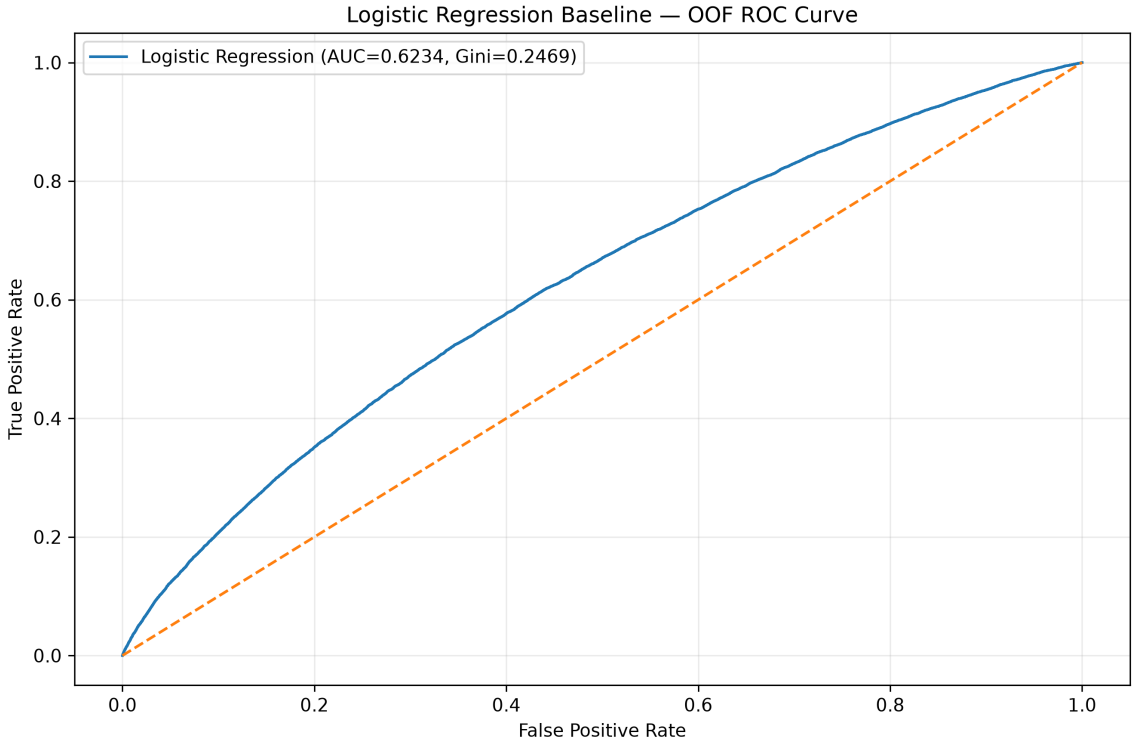


Abbildung 11: Out-of-Fold-ROC-Kurve der logistischen Regression (ROC-AUC = 0,6234; Gini = 0,2469).

Zusätzlich wurde die Klassifikation bei einem festen Schwellenwert betrachtet. Die Confusion Matrix verdeutlicht dabei ein wesentliches Problem der stark unausgeglichenen Zielvariable: Bei diesem Schwellenwert wurden sämtliche Beobachtungen der negativen Klasse zugeordnet. Dadurch wurden zwar 458 814 negative Fälle korrekt klassifiziert, jedoch alle 17 355 positiven Fälle übersehen.

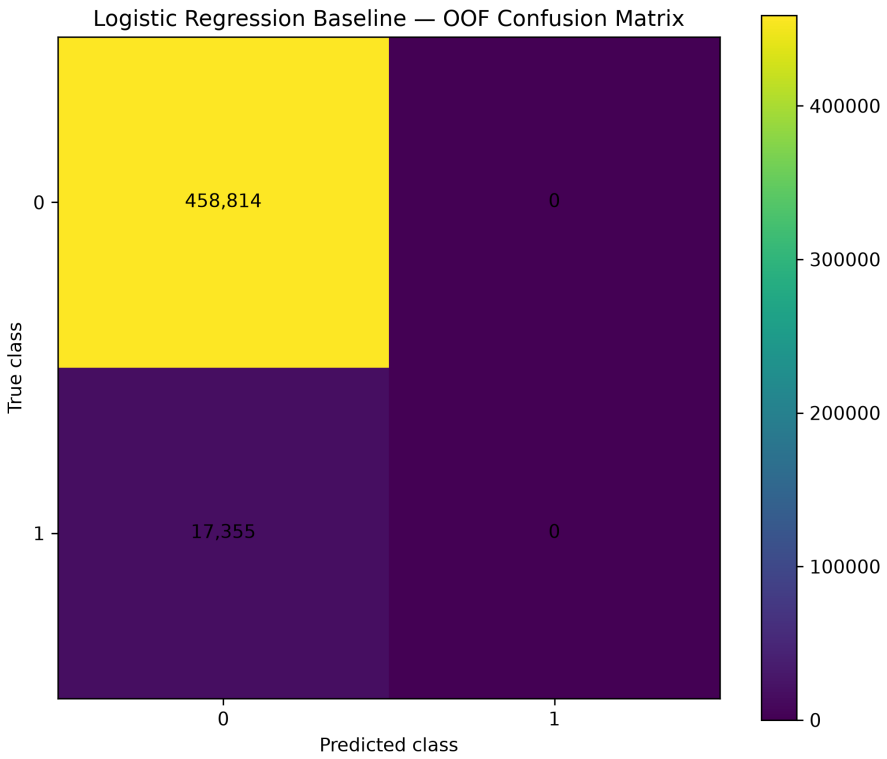


Abbildung 12: Out-of-Fold-Confusion-Matrix der logistischen Regression bei festem Klassifikationsschwellenwert.

Ergebnis / Konsequenz:

Die logistische Regression lieferte damit eine sinnvolle lineare Referenz, zeigte jedoch zugleich die Grenzen einer einfachen Klassifikationsentscheidung bei der stark unausgeglichenen Zielvariable. Insbesondere die Confusion Matrix unterstreicht, weshalb Accuracy bzw. eine reine Betrachtung der vorhergesagten Klassen für dieses Projekt ungeeignet wäre.

Für die weitere Modellbewertung wurden deshalb insbesondere die schwellenwertunabhängigen Ranking-Metriken ROC-AUC/Gini sowie ergänzend Average Precision betrachtet. Gleichzeitig motivierte die moderate ROC-AUC-Leistung der logistischen Regression die Untersuchung komplexerer, nichtlinearer Modelle wie XGBoost.

Sonntag, 09.08.2026 – XGBoost-Basismodell

Fragestellung:

Kann ein nichtlineares baumbasiertes Verfahren die Leistung der linearen Baseline verbessern?

Vorgehen:

Auf Grundlage der Entscheidung aus dem Gruppentreffen vom 08.08 wurde XGBoost als mein primärer Modellansatz implementiert. Zunächst wurde bewusst ein Basismodell ohne umfangreiches Tuning trainiert, um eine Referenz für die späteren Optimierungsschritte zu erhalten.

Ergebnis und nächste Frage:

XGBoost zeigte bereits als Basismodell eine bessere Eignung für die vorliegende Klassifikationsaufgabe als die lineare Referenz. Daraus ergab sich die nächste Fragestellung, welche Hyperparameterkombination die Modellleistung weiter verbessern könnte.

Mittwoch, 12.08.2026 – XGBoost-Hyperparameteroptimierung

Fragestellung:

Welche Hyperparameterkombination verbessert die XGBoost-Leistung, ohne eine vollständige und sehr rechenintensive Grid Search durchführen zu müssen?

Vorgehen:

Es wurde eine Randomized Search mit Cross-Validation durchgeführt. Die Konfigurationen wurden zunächst anhand von Average Precision bewertet, da die positive Klasse im Datensatz stark unterrepräsentiert ist.

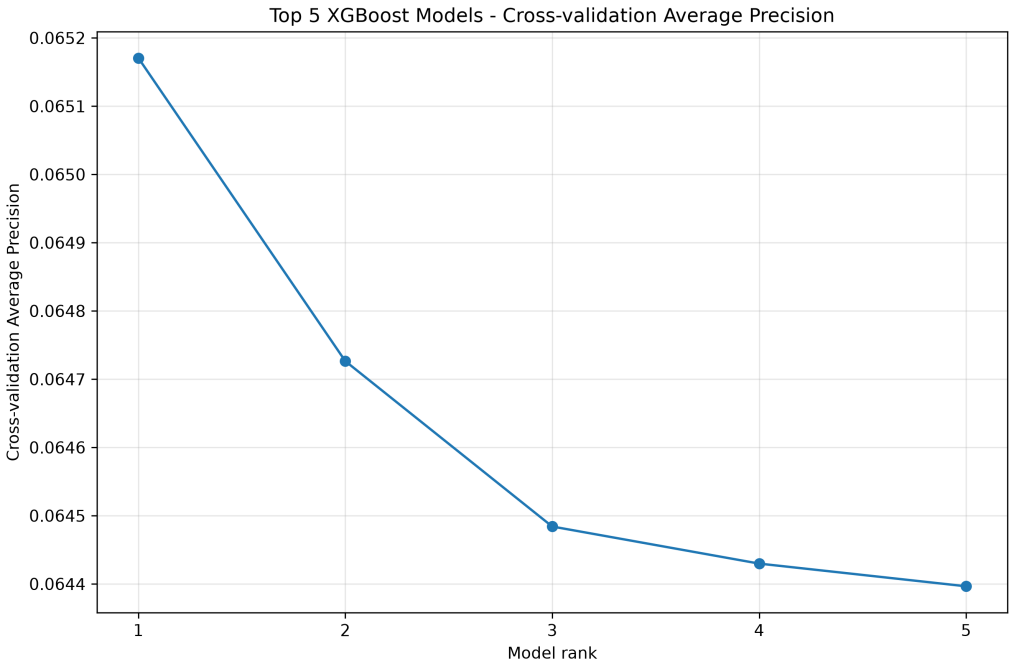


Abbildung 13: Top-Konfigurationen der XGBoost-Randomized-Search anhand der Cross-Validation-Average-Precision.

Ergebnis / Schwierigkeit:

Die Suche identifizierte mehrere leistungsfähige Kandidaten, war aber vergleichsweise rechenintensiv. Zudem stellte sich die Frage, ob eine Optimierung ausschließlich nach AP mit der im Gruppentreffen vereinbarten Hauptmetrik ROC-AUC/Gini konsistent ist.

Mittwoch, 12.08.2026 – AP- vs. ROC-AUC/Gini-Ranking

Fragestellung:

Ist die nach Average Precision beste XGBoost-Konfiguration auch nach ROC-AUC bzw. Gini die beste?

Vorgehen:

Die stärksten durch die Randomized Search identifizierten Konfigurationen wurden unter denselben Cross-Validation-Folds erneut evaluiert. Anschließend wurden die Rankings nach AP und ROC-AUC/Gini direkt miteinander verglichen.

Non-Weighted XGBoost — Average Precision vs ROC-AUC Ranking

Original_AP_Rank	AP_Rank	ROC_AUC_Rank	CV_AP	CV_ROC_AUC	CV_Gini
1.0	1.0	2.0	0.065171	0.636421	0.272842
2.0	2.0	1.0	0.064726	0.636804	0.273609
3.0	3.0	3.0	0.064484	0.636094	0.272188
4.0	4.0	5.0	0.06443	0.634436	0.268872
5.0	5.0	4.0	0.064397	0.63557	0.271139

Abbildung 14: Vergleich des Rankings nach Average Precision und ROC-AUC/Gini.

Ergebnis:

Die Rangfolge war nicht identisch. Die nach AP beste Konfiguration war nicht gleichzeitig die nach ROC-AUC/Gini beste Konfiguration.

Entscheidung:

Da Gini bereits im Gruppentreffen vom 08.08 als zentrale Vergleichsmetrik festgelegt worden war, wurde die XGBoost-Auswahl nicht nachträglich auf AP umgestellt. Stattdessen wurde ROC-AUC/Gini für die Hauptentscheidung verwendet und AP ergänzend dokumentiert.

Diese Entscheidung war später auch für die Ensemble- und finale Modellevaluation relevant.

Mittwoch, 12.08.2026 – Gewichtetes vs. nicht gewichtetes XGBoost

Fragestellung:

Kann die starke Klassenungleichverteilung durch eine stärkere Gewichtung der positiven Klasse ausgeglichen und dadurch die Modellleistung verbessert werden?

Vorgehen:

Gewichtete und nicht gewichtete XGBoost-Varianten wurden unter denselben gespeicherten Cross-Validation-Folds verglichen. Dadurch sollte verhindert werden, dass Unterschiede lediglich durch unterschiedliche Datenaufteilungen entstehen.

Controlled XGBoost Comparison – Same Configurations and Same CV Folds

Rank	NonWeighted_CV_AP	Weighted_CV_AP	Delta_AP	Delta_AP_Percent	Weighted_CV_ROC_AUC	Weighted_CV_Gini
1.0	0.065171	0.064657	-0.000513	-0.787675	0.635055	0.27011
2.0	0.064726	0.06266	-0.002066	-3.192497	0.628958	0.257917
3.0	0.064484	0.062802	-0.001682	-2.60889	0.628635	0.25727
4.0	0.06443	0.063935	-0.000495	-0.767711	0.633923	0.267846
5.0	0.064397	0.062406	-0.00199	-3.090584	0.628998	0.257996

Abbildung 15: Kontrollierter Vergleich gewichteter und nicht gewichteter XGBoost-Varianten.

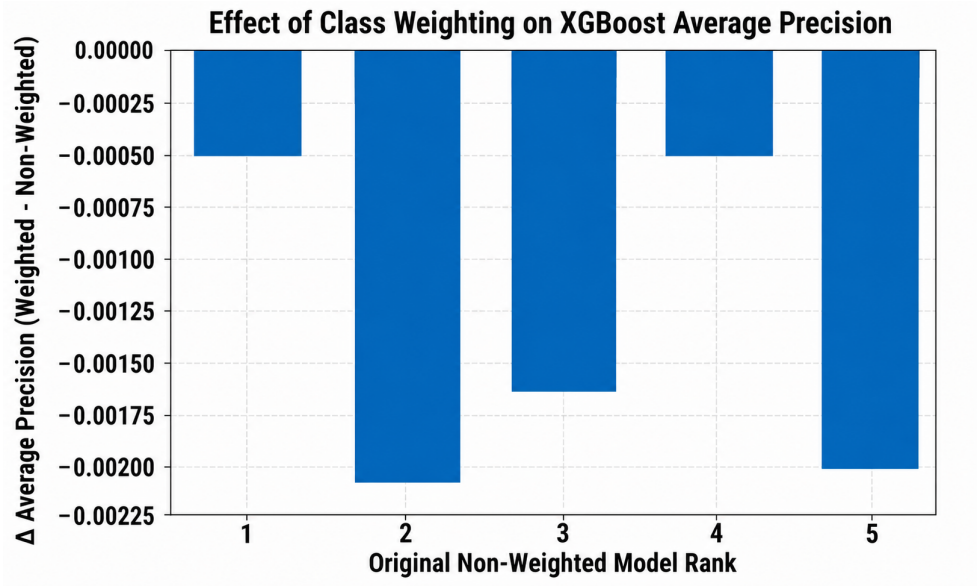


Abbildung 16: Einfluss der Klassengewichtung auf Average Precision.

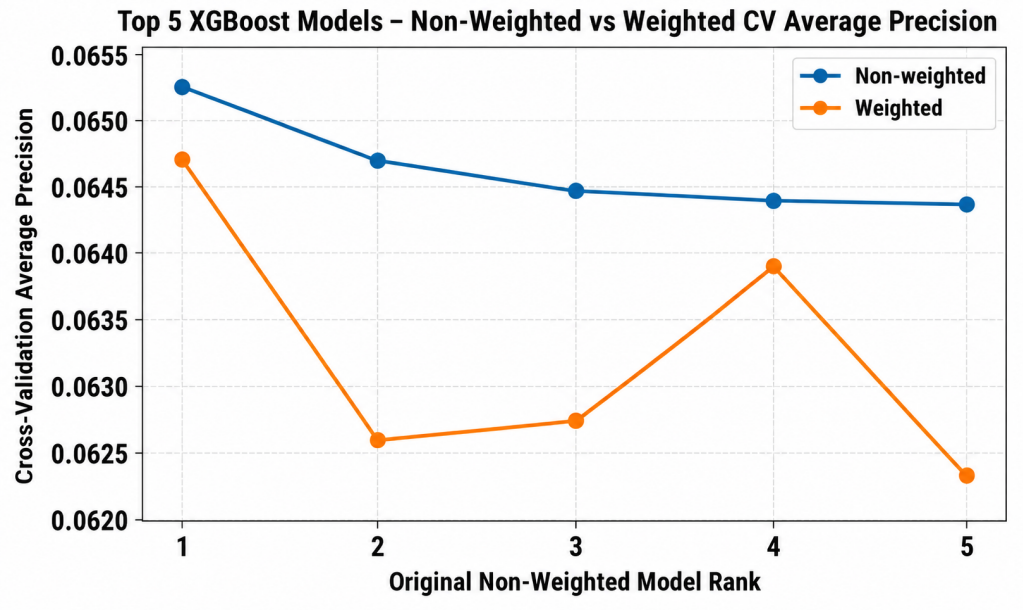


Abbildung 17: Direkter Vergleich der Average Precision von nicht gewichteten und gewichteten XGBoost-Konfigurationen.

Ergebnis:

Eine stärkere Gewichtung der positiven Klasse führte nicht automatisch zu einer Verbesserung der primären Evaluationsmetriken. Daher wurde die nicht gewichtete XGBoost-Variante für die weiteren Experimente bevorzugt.

Erkenntnis:

Die Klassenungleichverteilung allein war somit kein ausreichender Grund, eine Gewichtung zu verwenden. Die Wirkung musste empirisch überprüft werden.

Montag, 17.08.2026 – Lineare SVM: Baseline und Tuning

Fragestellung:

Wie schneidet ein zweiter, grundsätzlich anders aufgebauter Modellansatz gegenüber XGBoost ab, und kann er später zusätzliche Information für ein Ensemble liefern?

Vorgehen:

Nach einem linearen SVM-Basismodell wurden insbesondere der Regularisierungsparameter C und verschiedene Einstellungen von `class_weight` systematisch verglichen. Die Bewertung erfolgte wieder auf denselben Cross-Validation-Folds.

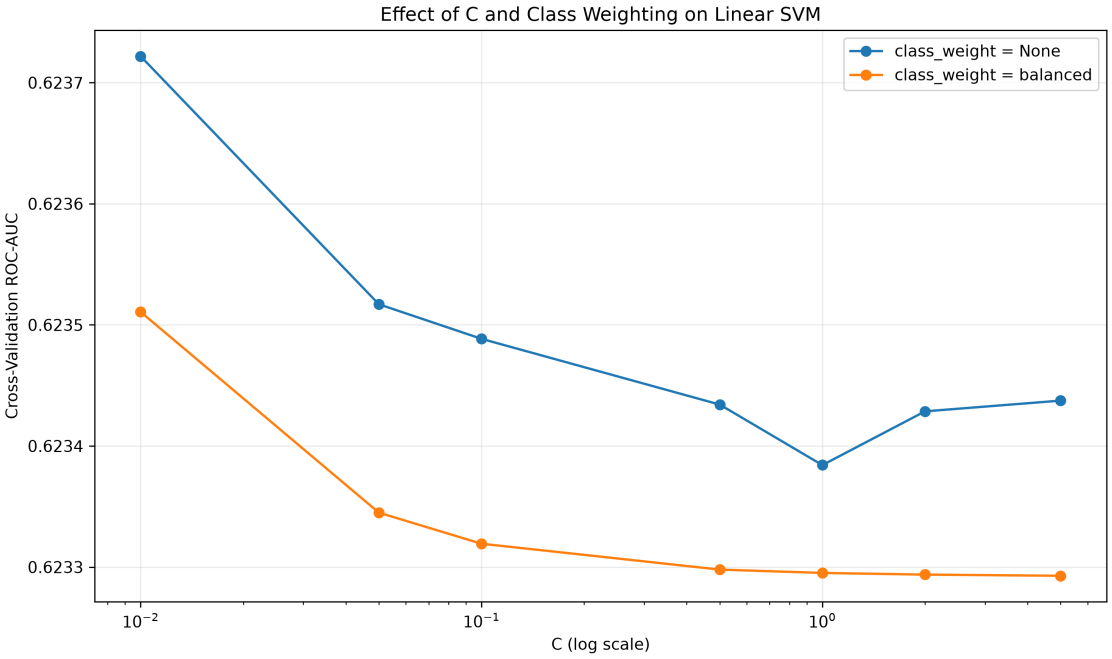


Abbildung 18: Einfluss von C und Klassengewichtung auf die SVM-Leistung.

Zusätzlich wurde geprüft, ob die Modellrangfolge nach ROC-AUC und AP auch bei der SVM voneinander abweicht.

Linear SVM — ROC-AUC Ranking vs Average Precision Ranking

C	class_weight	ROC_AUC_Rank	AP_Rank	CV_ROC_AUC	CV_Gini	CV_AP
0.01	None	1	1	0.623722	0.247444	0.060501
0.05	None	2	4	0.623517	0.247034	0.060371
0.01	balanced	3	2	0.623511	0.247021	0.060438
0.1	None	4	11	0.623488	0.246977	0.060339
5.0	None	5	12	0.623437	0.246875	0.060325
0.5	None	6	3	0.623434	0.246868	0.06038
2.0	None	7	13	0.623429	0.246857	0.060306
1.0	None	8	14	0.623384	0.246768	0.060266
0.05	balanced	9	5	0.623345	0.24669	0.060365
0.1	balanced	10	6	0.623319	0.246639	0.060353
0.5	balanced	11	10	0.623298	0.246596	0.060345
1.0	balanced	12	9	0.623295	0.24659	0.060345
2.0	balanced	13	8	0.623294	0.246588	0.060345
5.0	balanced	14	7	0.623293	0.246586	0.060345

Abbildung 19: Vergleich des SVM-Rankings nach ROC-AUC und AP.

Ergebnis:

Die optimierte SVM erreichte zwar keine XGBoost-Leistung, stellte aber einen methodisch unterschiedlichen Ansatz dar. Dadurch entstand die Frage, ob die Vorhersagen beider Modelle komple-

mentär genug sind, um durch ein Ensemble einen zusätzlichen Gewinn zu erzielen.

Montag, 17.08.2026 – Ensemble-Ansätze aus XGBoost und SVM

Fragestellung:

Kann die Kombination des stärkeren XGBoost-Modells mit der methodisch anders aufgebauten linearen SVM bessere Ergebnisse liefern als die Einzelmodelle?

Vorgehen:

Drei Varianten wurden untersucht:

- *Simple Average*: 50/50-Mittelwert beider Scores.
- *Weighted Average*: systematische Suche nach einem besseren Mischungsverhältnis.
- *Stacking*: Out-of-Fold-Vorhersagen von XGBoost und SVM als Eingabe für eine logistische Regression als Meta-Learner.

Bei der Gewichtssuche wurde untersucht, wie sich der XGBoost-Anteil auf den Cross-Validation-ROC-AUC auswirkt.

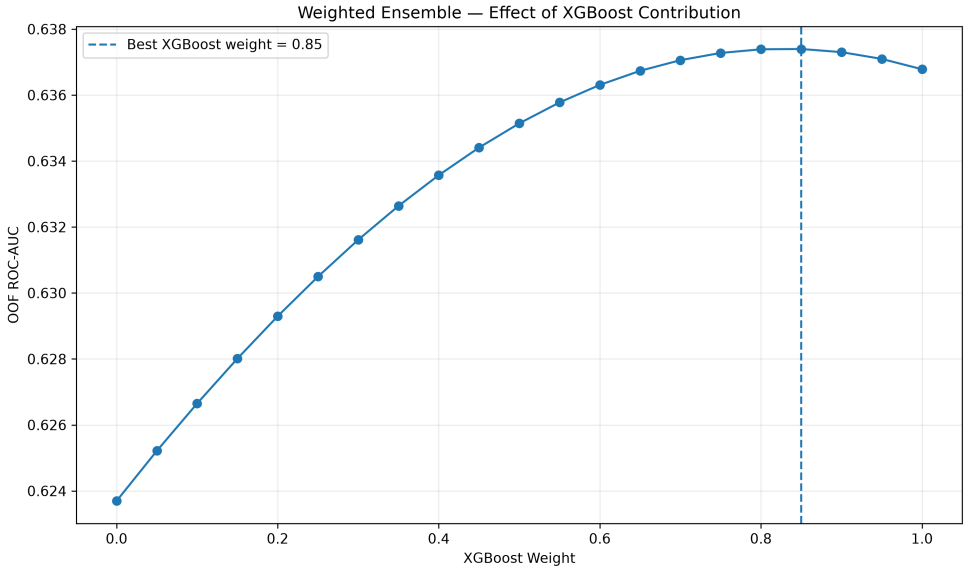


Abbildung 20: Einfluss des XGBoost-Gewichts auf den ROC-AUC des Ensembles.

Die drei Ensemble-Strategien wurden anschließend direkt verglichen.

Comparison of the Three XGBoost + SVM Ensemble Strategies

Method	ROC_AUC	Gini	Average_Precision	ROC_AUC_Rank	AP_Rank	Ensemble_ROC_AUC_Rank
Best Weighted Average	0.637398	0.274795	0.064281	1	2	1
Stacking	0.637304	0.274607	0.063846	2	3	2
Simple Average (50/50)	0.635143	0.270287	0.063436	4	4	3

Abbildung 21: Vergleich von Simple Average, Weighted Average und Stacking.

Ergebnis:

Das Weighted Average erzielte mit ROC-AUC 0,6374 die beste Cross-Validation-Leistung der drei Kombinationen. Stacking lag mit 0,6373 nahezu gleichauf, obwohl der Ansatz deutlich komplexer war.

Konsequenz:

Die zusätzliche Komplexität des Stackings erschien aufgrund des sehr kleinen Leistungsunterschieds zunächst nicht gerechtfertigt. Für die abschließende Evaluation wurden dennoch alle relevanten Varianten beibehalten, um diese Entscheidung auf dem zurückgehaltenen Testset zu überprüfen.

Mittwoch, 19.08.2026 – Finale Testevaluation der eigenen Modelle

Fragestellung:

Bestätigen sich die während der Cross-Validation beobachteten Unterschiede auch auf dem bisher vollständig zurückgehaltenen Testdatensatz?

Vorgehen:

Nach Abschluss der Modellauswahl wurden die finalen Varianten einmalig auf dem Testset evaluiert. Verglichen wurden logistische Regression, lineare SVM, XGBoost, Simple Average, Weighted Average und Stacking.

Final Test Set Performance — Logistic Regression, XGBoost, SVM and Ensembles

Model	Test_ROC_AUC	Test_Gini	Test_Average_Precision	ROC_AUC_Rank	AP_Rank
Best Weighted Average	0.640445	0.28089	0.065069	1	2
Stacking	0.640438	0.280876	0.064852	2	3
XGBoost	0.639774	0.279547	0.06674	3	1
Simple Average (50/50)	0.638405	0.27681	0.063611	4	4
Linear SVM	0.627712	0.255424	0.059901	5	6
Logistic Regression	0.627633	0.255266	0.060468	6	5

Abbildung 22: Finaler Vergleich der eigenen Modelle auf dem Testdatensatz.

Ergebnis:

Das Weighted Average erzielte mit ROC-AUC 0,6404 und Gini 0,2809 den höchsten Wert nach der zuvor festgelegten Hauptmetrik. Stacking lag praktisch gleichauf. XGBoost erreichte mit AP 0,0667 dagegen den höchsten Average-Precision-Wert.

Damit bestätigte sich erneut, dass die Modellrangfolge geringfügig von der betrachteten Metrik abhängt.

Interpretation:

XGBoost lieferte bereits als Einzelmodell fast die gesamte Vorhersageleistung des besten Ensembles. Die zusätzliche Kombination mit der SVM erzeugte nur einen kleinen Gewinn. Dies stellte die Frage, ob die zusätzliche Komplexität des Ensembles in einer praktischen Anwendung gerechtfertigt wäre.

Freitag, 21.08.2026 – Einfluss der `ps_calc`-Merkmale

Bezug zum Gruppentreffen vom 20.08.2026:

Während der Diskussion der bisherigen Ergebnisse wurde innerhalb der Gruppe auch der mögliche Einfluss der `ps_calc`-Merkmale thematisiert. Für den gemeinsamen Ergebnisvergleich wurde später beschlossen, die Modelle auf dem vollständigen Feature-Set zu vergleichen. Die Diskussion führte bei mir dennoch zu einem zusätzlichen individuellen Kontrollexperiment.

Fragestellung:

Verändert sich die Modellleistung messbar, wenn die `ps_calc`-Variablen aus dem Feature-Set entfernt werden?

Vorgehen:

Ausgewählte bereits trainierte Modellansätze wurden unter möglichst vergleichbaren Bedingungen einmal mit allen Merkmalen und einmal ohne die `ps_calc`-Merkmale evaluiert.

Ergebnis und Interpretation:

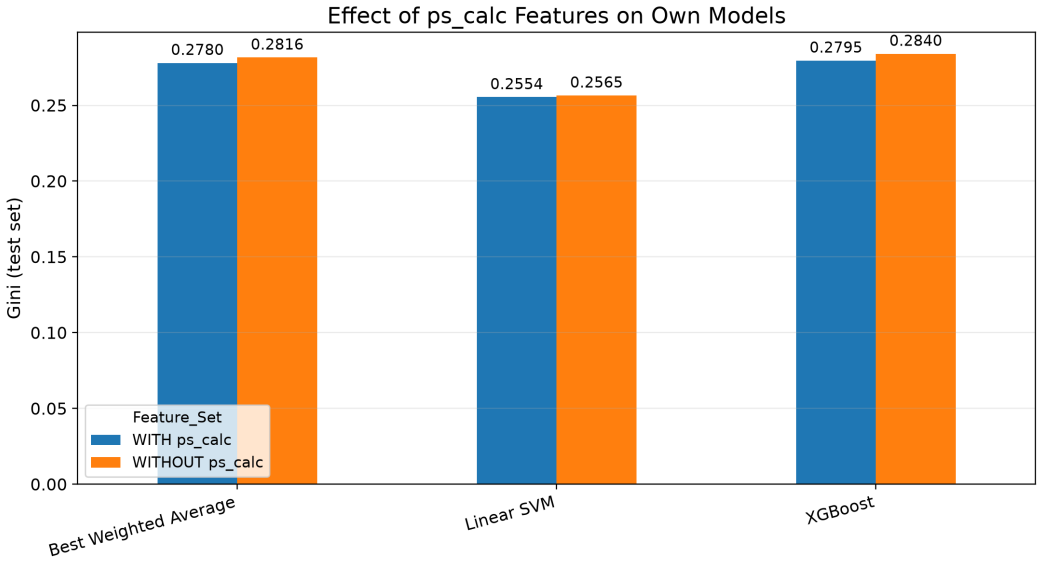


Abbildung 23: Vergleich der eigenen Modelle mit und ohne `ps_calc`-Merkmale.

Die Ergebnisse wurden als ergänzendes Ablationsexperiment betrachtet und nicht als Grundlage für die finale Modellauswahl verwendet. Entscheidend für den Gruppenvergleich blieb das vollständige Feature-Set.

Konsequenz:

Das Experiment zeigte, dass auch scheinbar schwach informative Merkmalsgruppen nicht allein aufgrund ihrer Bezeichnung oder Einzelwirkung entfernt werden sollten, sondern ihr Einfluss kontrolliert gemessen werden muss.

Freitag, 28.08.2026 – Abschluss und Einordnung der Ergebnisse

Bezug zum finalen Gruppentreffen:

Im finalen Treffen wurden die zuvor erstellten Entwürfe der Gruppenergebnisse gemeinsam diskutiert. Die Modellresultate wurden anhand der vereinbarten Metriken Gini und AP gegenübergestellt und die gemeinsame Ergebnisdarstellung abschließend abgestimmt.

Auswirkung auf meine Arbeit:

- Überprüfung, ob die in meinem Portfolio berichteten Modellwerte mit den für den Gruppenvergleich exportierten Ergebnissen übereinstimmen.
- Trennung zwischen meiner individuellen Modellentwicklung und dem gemeinsamen gruppenweiten Modellvergleich.
- Abschließende Einordnung des Weighted-Average-Ensembles als bestes eigenes Modell nach ROC-AUC/Gini, bei gleichzeitig sehr geringer Differenz zu XGBoost und Stacking.
- Dokumentation der Grenzen: begrenzter Hyperparameterraum, unterschiedliche Optimierungsintensität der Modelle und fehlende Wiederholung über mehrere Random Seeds.

Offener Ausblick:

Für weiterführende Arbeiten wären insbesondere wiederholte Evaluationen mit mehreren Seeds, Wahrscheinlichkeitskalibrierung und weitere Verfahren zur Merkmalsrepräsentation interessant.

4 Quellen und Hilfsmittel

Datensatz

- Howard, A., Moala, A. & Reade, W. (2017). *Porto Seguro's Safe Driver Prediction*. Kaggle Competition. https://www.kaggle.com/competitions/porto-seguro-safe-driver-prediction [Zugriff: Juli/August 2026].
- OpenML. *Porto Seguro Safe Driver Prediction*, Data ID 42742. Der Datensatz wurde im Notebook über `fetch_openml(data_id=42742)` geladen.

Bibliotheken und Software

- Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830. https://scikit-learn.org [Zugriff: August 2026].
- Chen, T. & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. https://xgboost.readthedocs.io [Zugriff: August 2026].
- McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference. https://pandas.pydata.org [Zugriff: Juli/August 2026].
- Harris, C. R. et al. (2020). *Array programming with NumPy*. Nature, 585, 357–362. https://numpy.org [Zugriff: Juli/August 2026].
- Hunter, J. D. (2007). *Matplotlib: A 2D Graphics Environment*. Computing in Science & Engineering, 9(3), 90–95. https://matplotlib.org [Zugriff: Juli/August 2026].

- Python Software Foundation. *Python 3*. https://www.python.org [Zugriff: Juli/August 2026].

Vorlesungsunterlagen

- Vorlesungs- und Übungsunterlagen des Moduls *Advanced Data Analytics*, Sommersemester 2026, Justus-Liebig-Universität Gießen.

Einsatz generativer KI

Im Rahmen des Projekts wurde ChatGPT (OpenAI) unterstützend eingesetzt. Die Nutzung umfasste insbesondere Debugging, Anpassungen und Strukturierung von Python-Code, Unterstützung bei der Planung einzelner Experimente sowie die sprachliche und technische Überarbeitung der LaTeX-Dokumentation.

Die Modellberechnungen und berichteten Kennzahlen wurden durch den ausgeführten eigenen Code erzeugt. Vorschläge der generativen KI wurden vor ihrer Übernahme geprüft und an den tatsächlichen Projektablauf und die berechneten Ergebnisse angepasst.

Beispielhafte Prompts:

- "Warum wird meine installierte `scikit-learn`-Bibliothek in diesem VS-Code-Environment nicht gefunden?"
- "Wie kann ich die besten XGBoost-Konfigurationen nach ROC-AUC/Gini erneut vergleichen, nachdem die Randomized Search zunächst nach Average Precision durchgeführt wurde?"
- "Wie kann ich gewichtete und nicht gewichtete XGBoost-Varianten unter denselben Cross-Validation-Folds fair vergleichen?"
- "Wie kann ich die Ergebnisse von XGBoost und SVM als Weighted Average bzw. Stacking kombinieren?"
- "Hilf mir, die Ergebnisse und Abbildungen meines Logbuchs in LaTeX kompakt und nachvollziehbar zu strukturieren."